

## Качество основной модели

```
val      | Accuracy: 0.8956
aligned  | Accuracy: 0.9966
flipped  | Accuracy: 0.0837
both     | Accuracy: 0.7213
```

## Shortcut is sensitive

0.9128440366972477

## Model Results

| Model       | Metric  | Q1     | Q2     | Q3     | Q4     |
|-------------|---------|--------|--------|--------|--------|
| Hyper-PCD   | auroc   | 0.9953 | 0.9584 | 0.9015 | 0.9077 |
| Hyper-PCD   | bal_acc | 0.9748 | 0.8779 | 0.8245 | 0.7781 |
| Static MLP  | auroc   | 0.9960 | 0.9556 | 0.9225 | 0.9064 |
| Static MLP  | bal_acc | 0.9610 | 0.8741 | 0.8263 | 0.7737 |
| Dense Hyper | auroc   | 0.9947 | 0.9474 | 0.8917 | 0.9120 |
| Dense Hyper | bal_acc | 0.9596 | 0.8736 | 0.8162 | 0.7665 |

## Diagnostic Hyper-PCD

Dead concepts (never active on intro\_train): 98 [/](#) 128

Top 3 concepts for Q1:

```
#1: concept 87 |r| = 0.5582
#2: concept 98 |r| = 0.4813
#3: concept 89 |r| = 0.4126
```

Top 3 concepts for Q4:

```
#1: concept 17 |r| = 0.3611
#2: concept 30 |r| = 0.3387
#3: concept 95 |r| = 0.2492
```

Best concept for Q1: 87 (|r|=0.5582)

Best concept for Q4: 17 (|r|=0.3611)

## Выводы

1. Выучила ли основная модель shortcut?

Да, и очень сильно. Accuracy на aligned — 99.7%, на flipped — 8.4% (почти инвертированная), доля shortcut\_sensitive на validation — 91.3%. Это означает, что модель в подавляющем большинстве случаев опирается на токен-подсказку, а не на смысл фразы.

2. Можно ли по  $h$  предсказывать наличие подсказки (Q1) и её конфликт с меткой (Q2)?

Да. Все три объясняющие модели достигают высокой accuracy по Q1 (98%) и умеренно высокой по Q2 (~89%). Это говорит о том, что присутствие и полярность токена-подсказки чётко отражаются в скрытом состоянии.

3. Можно ли по  $h$  предсказывать ошибки модели (Q3) и чувствительность к shortcut (Q4)?

Да, хотя точность ниже: Q3 ~85%, Q4 ~88–93%. Скрытое состояние несёт информацию об ошибочности предсказания и о том, изменит ли смена полярности подсказки ответ модели. Hyper-PCD справляется с Q4 наравне или лучше базовых моделей, что подтверждает полезность разреженного представления.

4. Что изменилось после абляции концепта, наиболее связанного с Q1?

После обнуления одного концепта (координаты  $z$  с максимальной корреляцией с Q1) качество предсказания Q1 заметно снижается — этот концепт был основным носителем информации о присутствии подсказки. Q2 и Q4, зависящие от того же признака, также деградируют. Q3 (ошибки модели) страдает меньше, поскольку его информация распределена по другим концептам. Это подтверждает интерпретируемость Hyper-PCD.